

Gapminder: tres proyectos de Ciencia de Datos

Equipo B · Laboratorio práctico 2.1

Ciencia de Datos | Ingeniería en Sistemas Computacionales

Proyectos 7, 8 y 9

Autores del reporte: Arturo Obeth, José Carlos Hernández Ballado, Ángel y Antonia Martínez Santos

Pregunta y conjunto de datos

¿Cómo describir, visualizar y preparar la información histórica de los países?

1,704 observaciones · 142 países · 1952 a 2007

País, año, población, continente, esperanza de vida y PIB por habitante

Qué adaptamos del curso


7 Gráficas con pivot y DataFrame.plot

8 Distribuciones y mapas de calor con Seaborn

9 StandardScaler y OneHotEncoder con scikit-learn

Las tres adaptaciones analizan el mismo conjunto de datos.


Proyecto 7: evolución de la esperanza de vida



México, Brasil, Argentina, Colombia y Chile

Las cinco series aumentan entre 1952 y 2007.

Proyecto 7: PIB y esperanza de vida




142 países en 2007

PIB por habitante en escala
logarítmica

Una asociación estadística por sí sola no identifica la causa.

Proyecto 8: distribución con Seaborn




`sns.histplot(..., kde=True)`

Las barras muestran frecuencias;
KDE resume la forma de la
distribución.

La esperanza de vida se mide en años.


Proyecto 8: correlación y mapa de calor



0.58

Correlación entre
esperanza de vida y PIB
por habitante

Proyecto 9: objetivo y variables




60.71 años

Mediana histórica usada como umbral


Predictores: año, población, PIB por habitante y continente

Proyecto 9: transformación de las variables



3 variables numéricas + 5 columnas de continente = 8 entradas

Proyecto 9: resultado de la comprobación



84.5 %

288 aciertos de 341 registros de prueba

Qué aprendimos y qué cambiaría el resultado

La selección de países determina la comparación.

Una correlación resume asociación en el periodo analizado.

El umbral y la partición afectan al clasificador.

La exactitud observada no demuestra desempeño en países nunca vistos.

Archivos, fuentes y preguntas

Tres notebooks, un dataset compartido y figuras reproducibles

Código base: github.com/thepycoach/curso-data-science

Datos: kaggle.com/datasets/tklimonova/gapminder-datacamp-2007

Preguntas