

Ciencia de Datos

2.1 Laboratorio Practico

EQUIPO: B

- Arturo Obed Velazque Tellez
- Angel de Jesús González Molina
- Antonia Martínez Santos
- José Carlos Hernandez Ballado



Que conjunto de datos usamos?

Usamos un mismo conjunto de datos para mostrar tres etapas: Visualizar la información, analizarla y prepararla para *Machine Learning*

El archivo `Gapminder_full.csv`

- Fuente:

<https://www.kaggle.com/datasets/tklimonova/gapminder-datacamp-2007>



Proyecto 7 - Visualización con Pandas

Creamos gráficas para comparar países y observar cómo cambian sus datos con el tiempo.



Proyecto 8 Gráficas con Seaborn

Exploramos la distribución de los datos y las relaciones entre variables, como PIB y esperanza de vida.



Preparación para Machine Learning

Transformamos y escalamos las variables para que los datos puedan usarse en un modelo.



¿Qué contiene Gapminder?

Gapminder reúne datos de distintos países a lo largo del tiempo. Nos permite comparar su población, esperanza de vida y PIB por habitante, e identificar a qué continente pertenece cada uno.

Una fila = un país en un año específico

- 1,704 registros
- 142 países
- desde el año 1952 al 2007



EJEMPLO :

country	year	population	continent	life_exp	gdp_cap
Mexico	2007	108,700,891	Americas	76.2	11,978

El recorrido del equipo

7

- **Ver cambios entre países y años**

Usamos gráficas de líneas y dispersión para comparar países y observar cambios entre 1952 y 2007.

8

- **Explorar distribuciones y relaciones**

Analizamos cómo se distribuye la esperanza de vida y qué relación tiene con el PIB por habitante.

9

- **Preparar las columnas para un modelo**

Escalamos los datos numéricos y convertimos el continente de texto a números para preparar la información para un modelo.

Trabajamos con el mismo archivo Gapminder en tres etapas: primero visualizamos los datos, después buscamos patrones y finalmente los preparamos para machine learning.



V PROYECTO 7

Del ejemplo del curso a Gapminder

Código original del curso
(Frank Andrade / ThePyCoach)

```
df_pivot =  
df_population_raw.pivot(  
    index='year',  
    columns='country',  
    values='population'  
)  
df_pivot.plot(kind='line')
```

Cambiamos poblacion por esperanza de vida y seleccionamos 5 países. `pivot()` acomoda los años en filas y los países en columnas; `plot(kind='line')` dibuja las líneas


En nuestra adaptación

```
tabla = df.pivot(  
    index='year',  
    columns='country',  
    values='life_exp'  
)  
tabla.plot(kind='line')
```

PROYECTO 7


Dos formas de mirar los datos

Esperanza de vida en Latinoamérica (1952-2007)



La esperanza de vida aumentó en los cinco países latinoamericanos durante el periodo analizado.

Riqueza vs. esperanza de vida, 142 países (2007)



En 2007, los países con mayor PIB por habitante tendían a tener mayor esperanza de vida. Es una relación observada, no una prueba de causa.

PROYECTO 8

Distribuciones & relaciones

Dos preguntas que respondimos

- ¿Cómo se distribuye la esperanza de vida?

```
sns.histplot(data=df, x='life_exp',  
             kde=True)
```


- ¿Qué variables cambian juntas?

```
sns.heatmap(df[variables].corr(),  
            annot=True)
```



PROYECTO 8


Esperanza de vida



¿Qué estamos viendo?
Se agruparon los 1,704 registros de países y años según su esperanza de vida. Los valores se concentran especialmente cerca de los 70 años; esta gráfica muestra frecuencias, no identifica países individuales.

PROYECTO 8

Mapa de calor



¿Qué encontramos?

La relación entre PIB por habitante y esperanza de vida es positiva y moderada (0.58): en estos datos, los valores altos de una variable suelen acompañarse de valores altos de la otra.

Esto muestra una asociación, no demuestra que el PIB sea la causa.

La relación es positiva. La gráfica no demuestra una causa.

V PROYECTO 9

Qué cambiamos del código base

Ejemplo del curso

```
df_boston = pd.read_csv('Boston House  
Prices.csv')
```

Nuestro caso

```
df =  
pd.read_csv('gapminder_full.csv')  
  
X = df[['year', 'population',  
        'gdp_cap', 'continent']]
```

En el curso se cargan datos de precios de casas. Nosotros cargamos Gapminder y seleccionamos cuatro columnas para preparar un modelo que distinga registros con esperanza de vida alta o baja.

V

PROYECTO 9 preparar las variables

Antes —una fila de México

Año	Población	PIB por habitante	Continente
2007	108.7 millones	11,978	Americas


Después —datos preparados para el modelo

Año, población y PIB	Africa	Americas	Asia	Europe	Oceania
Valores escalados	0	1	0	0	0

Las tres variables numéricas se escalan para que sus tamaños sean comparables. El continente, que era texto, se representa con cinco columnas de 0 y 1. Así pasamos de 4 columnas de entrada a 8 columnas numéricas.

V PROYECTO 9 una comprobación con un modelo

Matriz de confusión - validación del preprocesamiento



288 de 341 predicciones correctas (84.5 %)

Después de preparar los datos, probamos una regresión logística sencilla. Acertó en 147 casos de esperanza de vida baja y 141 de esperanza de vida alta; se equivocó en 53 casos.

V CONCLUSIONES

7 · VISUALIZACIÓN: EN LOS CINCO PAÍSES LATINOAMERICANOS COMPARADOS, LA ESPERANZA DE VIDA AUMENTÓ ENTRE 1952 Y 2007.

8 · ANÁLISIS ESTADÍSTICO: EN GAPMINDER OBSERVAMOS UNA RELACIÓN POSITIVA ENTRE PIB POR HABITANTE Y ESPERANZA DE VIDA (CORRELACIÓN DE 0.58). ESTO NO DEMUESTRA UNA CAUSA.

9 · PREPROCESAMIENTO: CONVERTIMOS CUATRO VARIABLES DE ENTRADA EN OCHO COLUMNAS NUMÉRICAS Y COMPROBAMOS QUE PODÍAN UTILIZARSE EN UN MODELO.

CONCLUSIÓN GENERAL: CON EL MISMO DATASET PASAMOS DE VISUALIZAR LOS DATOS A EXPLORAR SUS RELACIONES Y PREPARARLOS PARA MACHINE LEARNING.