



INGENIERÍA EN SISTEMAS COMPUTACIONALES

Materia:

Ciencia de Datos



VERACRUZ
GOBIERNO
DEL ESTADO

Semestre - Grupo - Sistema:

7° – Único – Semiescolarizado.



SEV
Secretaría
de Educación

Producto Académico:

Práctica 2.1

Reporte de los otros nueve temas



DET
Dirección de Educación
Tecnológica del Estado
de Veracruz



Presenta(n):

Arturo Obed Velazque Tellez
José Carlos Hernández Ballado
Ángel de Jesús González Molina
Antonia Martínez Santos



Docente:

Fernando Mayorga Guittins



Carrera		Clave de materia	Nombre de la materia	
Ingeniería en Sistemas Computacionales			Ciencia de Datos	
Unidad	Practica No.	Nombre de la Practica		Duración (Horas)
2	2.1	Laboratorio Practico		2

1. INSTRUCCIONES

La consigna del laboratorio 2.1 solicita un PDF con evidencia de la aplicación de los nueve proyectos fuera de los asignados al Equipo B. Este reporte corresponde a los temas 1 a 6 y 10 a 12 de la guía; el notebook **Evidencia_otros_9_temas.ipynb** y el CSV incluidos permiten revisar el código y sus salidas.

2. INTRODUCCIÓN

Se realizaron nueve ejercicios breves con **Gapminder**: extracción, limpieza, filtrado, agrupación, tabla dinámica, unión, modelo base, búsqueda de parámetros y evaluación. El dataset tiene 1,704 registros país-año y seis columnas, con 142 países y doce años entre 1952 y 2007.

3. OBJETIVOS (COMPETENCIAS)

Aplicar las operaciones principales de los nueve temas restantes y conservar evidencia verificable de sus resultados. Interpretar los resultados sin atribuir causalidad a una correlación ni capacidad de generalización a países nuevos a partir de una partición aleatoria por filas.

4. FUNDAMENTO

Pandas lee y transforma tablas. Los filtros y groupby permiten seleccionar y resumir observaciones; **pivot_table** reorganiza medidas y concat/merge reúnen conjuntos. En clasificación, el árbol de decisión ofrece un modelo base, **GridSearchCV** compara parámetros mediante validación cruzada y la matriz de confusión detalla aciertos y errores en el conjunto de prueba.

5. EQUIPAMIENTO Y MATERIAL DE APOYO

- **Equipo:** Computadora y Google Colab o Jupyter Notebook.
- **Datos:** gapminder_full.csv, incluido en el ZIP.
- **Código:** evidencia_otros_nueve/Evidencia_otros_9_temas.ipynb.
- **Bibliotecas:** pandas, numpy, scikit-learn y lxml para leer HTML.

6. DESARROLLO DE LA PRÁCTICA

Proyecto 1. Extracción de datos

Procedimiento. Se creó una tabla HTML local a partir de tres países de 2007 y se recuperó con `pd.read_html(StringIO(html))`.

Resultado. Se obtuvo una tabla de 3 filas y 3 columnas. Es una prueba de extracción desde HTML local; no hubo consulta a un sitio web en vivo.

Proyecto 2. Limpieza de datos

Procedimiento. Se introdujeron deliberadamente un valor faltante y una fila duplicada en una copia pequeña. Se aplicaron `drop_duplicates` y `fillna` con la mediana.

Resultado. La muestra pasó de 1 nulo y 1 duplicado a 0 nulos y 0 duplicados; el CSV original quedó intacto.

Proyecto 3. Manipulación y filtrado

Procedimiento. Se usó una máscara booleana con año 2007 y los países México y Brasil, junto con `loc` e `iloc`.

Resultado. El filtro devolvió 2 registros y se extrajo una fila por posición.

Proyecto 4. Agrupación

Procedimiento. Se seleccionó 2007 y se agruparon los datos por continente con `groupby().agg()` para media, mediana y cantidad de países.

Resultado. Se obtuvieron 5 grupos. El promedio de esperanza de vida fue de 54.81 años en África y 73.61 en América.

Proyecto 5. Tabla dinámica

Procedimiento. Se calculó con `pivot_table` el promedio de esperanza de vida por año y continente.

Resultado. La tabla resultante tiene 12 filas de años por 5 columnas de continentes.

Proyecto 6. Unión de tablas

Procedimiento. Se reconstruyó el archivo con `concat` a partir de dos periodos y se cruzaron dos subconjuntos por país y año con `merge`.

Resultado. Ambas operaciones conservaron 1,704 filas. La validación `one_to_one` comprobó claves únicas en la unión.

Proyecto 10. Modelo base

Procedimiento. Se creó una clase binaria según la mediana histórica de esperanza de vida. Las entradas fueron año, población, PIB por habitante y continente; `life_exp` quedó fuera de las entradas. Se entrenó un árbol de profundidad 3 en una partición estratificada de 1,363 filas de entrenamiento y 341 de prueba.

Resultado. La exactitud del árbol base en prueba fue 0.877. La partición y el preprocesamiento se encuentran en el notebook.

Proyecto 11. Búsqueda de parámetros

Procedimiento. GridSearchCV evaluó nueve combinaciones de profundidad máxima y mínimo de muestras por hoja, con tres pliegues solamente en entrenamiento.

Resultado. El mejor promedio de validación fue 0.891. Parámetros seleccionados: profundidad 5 y mínimo de 15 muestras por hoja.

Proyecto 12. Evaluación

Procedimiento. El modelo seleccionado se aplicó al conjunto de 341 filas de prueba y se calcularon `accuracy_score`, `confusion_matrix` y `classification_report`.

Resultado. La exactitud fue 0.880. La matriz de confusión fue $\begin{bmatrix} 149 & 22 \\ 19 & 151 \end{bmatrix}$, con filas reales y columnas predichas: 149 bajas y 151 altas correctas, 41 errores en total.

7. RESULTADOS Y CONCLUSIONES

Los ejercicios cubren nueve temas de la guía. La evaluación mezcla distintos años de un mismo país entre entrenamiento y prueba, por lo que la exactitud no mide rendimiento en países nuevos.

Esta evidencia consiste en ejercicios propios. La extracción usa HTML local y el notebook no muestra la ejecución literal de los archivos originales de Frank Andrade.

8. ANEXOS

Se incluye `Evidencia_otros_9_temas.ipynb` con diez celdas de código ejecutadas y sus salidas, además de `gapminder_full.csv` para repetir la práctica en Colab.

9. REFERENCIAS

- Andrade, F. (s. f.). Curso Data Science [Código fuente]. GitHub.
<https://github.com/thepycoach/curso-data-science>
- Klimonova, T. (s. f.). Gapminder DataCamp 2007 [Conjunto de datos]. Kaggle.
<https://www.kaggle.com/datasets/tklimonova/gapminder-datacamp-2007>
- Mayorga Guittins, F. (2026). CD 2.1 Laboratorio Práctico [Consigna de clase]. ITSav.